



**OBÓZ NAUKOWY
POLITECHNIKI WARSZAWSKIEJ**

Centrality & Community Detection

Dzień 4




Centrality algorithms

- Degree Centrality
- Closeness Centrality
- Betweenness Centrality



Degree Centrality

- ilość wierzchołków wchodzących + wychodzących z wierzchołka (stopień wierzchołka)



Closeness Centrality

- odwrotność sumy odległości wierzchołka do wszystkich pozostałych


$$C(u) = \frac{1}{\sum_{v=1}^{n-1} d(u, v)} \quad C_{norm}(u) = \frac{n-1}{\sum_{v=1}^{n-1} d(u, v)}$$

- n - ilość wierzchołków
- v - kolejne wierzchołki
- $d(u, v)$ - odległość między wierzchołkami u i v



Closeness Centrality

- Szukanie wpływowych części sieci
 - influencerzy na FB/IG
 - terroryści
 - sieci neuronowe
- szybkość czasu przesyłki



Betweenness Centrality

- Liczymy najkrótsze drogi między wszystkimi wierzchołkami
- Jeżeli przez wierzchołek przechodzi dużo takich połączeń to ma wysoki wskaźnik
- Szukanie “mostów” w grafie
- najpopularniejszy \neq najważniejszy





Betweenness Centrality

- u - wierzchołek
- p - ilość najkrótszych ścieżek w grafie
- $p(u)$ - ilość najkrótszych ścieżek przechodzących przez u

$$B(u) = \sum_{s \neq u \neq t} \frac{p(s, t)}{p}$$







Node D Calculation

Pairs with Shortest Paths Through D	Total Possible Shortest Paths for That Pair	% of Total Through D (1/Total)
A, E	1	1
B, E	1	1
C, E	1	1
B, C	2 (through D & A)	0.5
Betweenness Score		3.5




Community Detection

- k-means clustering




k -Średnich

Before K-Means



K-Means

After K-Means



k-Średnich

- algorytm NIEgrafowy
- grupowanie punktów w k klastrów
- algorytm deterministyczny



k -Średnich

1. wybieramy k przypadkowych centroidów
2. przypisujemy punkty do najbliższych centroidów
3. ustawiamy centroidy na środek klastrów
4. powtarzamy kroki 2 i 3, aż układ jest stabilny



